

Classificação Supervisionada como Suporte à Priorização de Transações em Auditoria de Fraude em Cartão de Crédito

Anna J. A. Lucas¹, João V. M. Senra²

Departamento de Ciência da Computação (DCC)

Universidade Federal de Juiz de Fora (UFJF)

Juiz de Fora – MG – Brasil

¹almeidaanna.julia@gmail.com, ²joaovictor.senra@estudante.ufjf.br

Abstract. Credit card fraud detection represents a critical operational challenge for financial audit teams. Given that only 0.17% of transactions are fraudulent, no team can review all occurrences, making prioritization a central problem. This work proposes a decision support system based on supervised classification to answer the research question: *How can a classification model support the prioritization of transactions to be investigated by an audit team with limited capacity?* Using the real Credit Card Fraud Detection dataset (Worldline/ULB, 284,807 real transactions, September 2013), two models were developed and compared — Logistic Regression (baseline) and Random Forest —, evaluated by PR-AUC, appropriate for the extreme class imbalance. The Random Forest model achieved PR-AUC of 0.815, precision of 98.75%, and recall of 73.15% on the fraud class. A capacity analysis shows that reviewing 85 transactions per day captures 75.9% of all frauds with 96.5% precision, directly answering the research question.

Resumo. A detecção de fraude em cartões de crédito representa um desafio operacional crítico para equipes de auditoria financeira. Dado que apenas 0,17% das transações são fraudulentas, nenhuma equipe consegue revisar a totalidade das ocorrências, tornando a priorização um problema central. Este trabalho propõe um sistema de apoio à decisão baseado em classificação supervisionada para responder à pergunta-problema: *Como um modelo de classificação pode apoiar a priorização de transações a serem investigadas por uma equipe de auditoria com capacidade limitada?* Utilizando o dataset real Credit Card Fraud Detection (Worldline/ULB, 284.807 transações reais, setembro de 2013), foram desenvolvidos e comparados dois modelos — Regressão Logística (baseline) e Random Forest —, avaliados pela métrica PR-AUC, adequada ao extremo desbalanceamento de classes. O Random Forest alcançou PR-AUC de 0,815, precisão de 98,75% e recall de 73,15% na classe fraude. Uma análise de capacidade demonstra que, ao revisar 85 transações por dia, a equipe captura 75,9% de todas as fraudes com 96,5% de precisão.

1 Introdução

A fraude em cartão de crédito consiste no uso não autorizado dos dados ou do cartão físico de um cliente legítimo por um terceiro, sem seu conhecimento ou consentimento. Nesse cenário, o portador real da conta não reconhece a operação como sua e a contesta junto à instituição financeira. Essa modalidade distingue-se de outras formas de fraude financeira, como fraude de identidade (obtenção fraudulenta de crédito), lavagem de dinheiro e fraude pelo próprio titular do cartão.

O combate a esse tipo de fraude impõe às equipes de auditoria financeira um desafio operacional de natureza dupla. Por um lado, a baixíssima prevalência do evento fraudulento — da ordem de 0,17% do total de transações — torna a detecção tecnicamente difícil com métricas convencionais; por outro,

a capacidade humana de investigação é finita e frequentemente inferior ao volume de alertas gerados pelos sistemas automatizados. Consequentemente, o problema não se limita à classificação correta das transações, mas à priorização adequada dos casos a investigar dada uma restrição operacional real.

No contexto de Sistemas de Apoio à Decisão (SAD), tal cenário configura um problema de otimização sob restrição: maximizar a cobertura de fraudes dentro da capacidade diária de revisão disponível. A abordagem proposta neste trabalho combina duas camadas técnicas: (i) um modelo de classificação supervisionada para atribuir a cada transação uma probabilidade de ser fraude, ordenando a fila de investigação; e (ii) uma análise de capacidade (modelagem *what-if*) para identificar, dado um nível de capacidade da equipe, quantas fraudes são capturadas e qual a precisão dos alertas gerados.

Pergunta-problema: como um modelo de classificação pode apoiar a priorização de transações a serem investigadas por uma equipe de auditoria com capacidade limitada?

O objetivo geral é desenvolver e avaliar um sistema de apoio à decisão que permita à equipe de auditoria priorizar transações suspeitas de acordo com a probabilidade de fraude. Os objetivos específicos são: (a) explorar e caracterizar o dataset real de fraude em cartão de crédito; (b) implementar e comparar modelos de classificação com métricas adequadas ao desbalanceamento de classes; e (c) simular cenários de capacidade de revisão diária para embasar a decisão operacional.

2 Base de Dados e Definição do Problema

2.1 Definição Operacional de Fraude

Neste trabalho, considera-se fraude (Class = 1) toda transação de cartão de crédito realizada por um terceiro não autorizado utilizando os dados ou o cartão físico de um cliente legítimo, sem o seu conhecimento ou consentimento. Essa modalidade distingue-se de fraude de identidade, lavagem de dinheiro ou fraude pelo próprio titular. O portador legítimo não reconhece a transação como sua e a contesta junto à instituição. Os rótulos foram atribuídos retrospectivamente pela equipe de investigação da Worldline, mediante cruzamento de contestações dos clientes com os registros das operações.

2.2 Dataset

O dataset *Credit Card Fraud Detection* [7], produzido pela colaboração entre a Worldline e o Machine Learning Group (MLG) da Université Libre de Bruxelles (ULB), contém 284.807 transações reais de cartões de crédito de portadores europeus, ocorridas em setembro de 2013, distribuídas em aproximadamente dois dias consecutivos [2]. Do total, 492 transações (0,1727%) foram confirmadas como fraudulentas, caracterizando um problema de classes fortemente desbalanceadas.

O dataset possui 31 colunas: *Time* (segundos decorridos desde a primeira transação do período), *Amount* (valor da transação em euros) e *V1–V28*, que correspondem a 28 componentes de uma transformação PCA aplicada sobre as variáveis originais — anonimizadas por razões de confidencialidade comercial. A variável *Class* é o rótulo binário (0 = legítima; 1 = fraude confirmada). Não foram identificados valores nulos no conjunto de dados.

2.3 Análise Exploratória de Dados (EDA)

A Figura 1 evidencia o desbalanceamento extremo entre as classes. Um modelo ingênuo que classifique todas as transações como legítimas alcançaria 99,83% de acurácia — sem detectar nenhuma fraude. Isso justifica a adoção de métricas especializadas, detalhadas na Seção 3.3.




Figura 1. Distribuição das classes: 284.315 transações legítimas (99,83%) vs. 492 fraudes confirmadas (0,17%).

A Figura 2 apresenta o padrão temporal das transações por hora do dia, normalizado pelo total de cada classe. Observa-se que as fraudes apresentam picos de volume às 2h e às 11h — padrão distinto das transações legítimas, que seguem um perfil diurno mais regular. Esse comportamento sugere que a hora do dia é uma variável contextual relevante para a classificação, motivo pelo qual foi incorporada como *feature* derivada de *Time*.




Figura 2. Distribuição percentual de transações legítimas e fraudulentas por hora do dia. Fraudes apresentam picos noturnos e matinais distintos do padrão das transações legítimas.

3 Metodologia

3.1 Pré-processamento

O pré-processamento seguiu as seguintes etapas:

- **Feature engineering:** a variável `Hour` foi derivada de `Time` como $\lfloor \text{Time} \div 3600 \rfloor \bmod 24$, capturando a ciclicidade diária sem vazamento de informação.
- **Split temporal:** os dados foram ordenados cronologicamente e divididos em 70% para treino (passado) e 30% para teste (futuro). Essa estratégia simula o cenário real de auditoria, no qual o modelo é treinado com histórico e aplicado a transações novas — evitando o vazamento temporal (*data leakage*) que ocorreria com um split aleatório.
- **Normalização:** as variáveis `Amount` e `Hour` foram padronizadas com `StandardScaler`, ajustado exclusivamente no conjunto de treino. As variáveis `V1–V28`, já em escala homogênea por construção do PCA, não foram reescaladas.
- **Tratamento do desbalanceamento:** foi adotado o parâmetro `class_weight='balanced'` em todos os modelos, que pondera cada classe proporcionalmente ao inverso de sua frequência, sem gerar amostras artificiais e preservando a distribuição real do fenômeno.

3.2 Modelos de Classificação

Foram implementados dois modelos: Regressão Logística (LR), utilizada como *baseline* por sua interpretabilidade e eficiência computacional; e Random Forest (RF), escolhido como modelo principal por sua robustez ao desbalanceamento, capacidade de capturar interações não lineares entre variáveis e adequação a cenários de alta dimensionalidade com *features* latentes (como as componentes PCA `V1–V28`). O RF foi configurado com 300 árvores e profundidade máxima de 12, valores determinados por validação empírica no conjunto de treino. Ambos os modelos foram implementados com a biblioteca `scikit-learn` [5].

3.3 Métricas de Avaliação

A acurácia é uma métrica inadequada para dados com desbalanceamento extremo: um modelo que classifique tudo como legítimo alcançaria 99,83% de acurácia sem detectar nenhuma fraude. Por essa razão, adotam-se métricas voltadas à classe de interesse [3]:

- **PR-AUC** (área sob a curva Precisão-Recall): métrica primária de comparação entre modelos. Mede a qualidade de priorização ao longo de todos os limiares de decisão possíveis.
- **Precisão:** proporção de alertas corretos sobre o total de alertas emitidos (impacta o custo operacional de investigações indevidas).
- **Recall:** proporção de fraudes reais capturadas sobre o total de fraudes existentes (impacta diretamente o prejuízo evitado).

3.4 Análise de Capacidade (Modelagem *What-If*)

Para conectar o algoritmo à decisão operacional, foi implementada uma análise de capacidade: as transações do conjunto de teste são ordenadas de forma decrescente pelo *score* de probabilidade de fraude atribuído pelo RF. Para cada nível de capacidade diária K (número de casos que a equipe consegue revisar por dia), calcula-se o recall e a precisão obtidos ao inspecionar os K casos com maior *score*. Essa abordagem responde diretamente à pergunta-problema: dado que a equipe tem capacidade K , o modelo identifica quais K transações têm maior probabilidade de serem fraudes, maximizando a cobertura dentro da restrição operacional.

4 Resultados e Discussão

4.1 Comparação dos Modelos

A Tabela 1 apresenta as métricas de desempenho de ambos os modelos no conjunto de teste (split temporal 70/30).

Tabela 1. Métricas de desempenho dos modelos no conjunto de teste. ★ Modelo selecionado como principal (melhor PR-AUC).

Modelo	ROC-AUC	PR-AUC	Precisão	Recall	F1
Reg. Logística (baseline)	0,980	0,776	0,027	0,907	0,052
Random Forest ★	0,973	0,815	0,988	0,732	0,840

A Regressão Logística, apesar do alto recall (0,907), apresenta precisão extremamente baixa (0,027): para cada fraude detectada, gera aproximadamente 36 falsos positivos — o que inviabilizaria a operação de auditoria por saturar a equipe com alertas incorretos. O Random Forest alcança equilíbrio superior: precisão de 98,75% significa que praticamente todos os alertas emitidos são fraudes reais, e recall de 73,15% indica cobertura satisfatória do conjunto de fraudes existentes. O F1-score de 0,840 confirma o desempenho global superior do RF.

Quanto à PR-AUC, métrica primária de comparação, o RF (0,815) supera a LR (0,776) por significativa margem, indicando melhor capacidade de priorização ao longo de todos os limiares de decisão possíveis.

4.2 Curva Precisão-Recall

A Figura 3 ilustra as curvas Precisão-Recall de ambos os modelos. O RF mantém precisão próxima a 100% para recalls de até $\approx 60\%$ — regime de alta confiança em que todos os alertas são fraudes reais. A partir de 75% de recall, a precisão reduz progressivamente, refletindo a inclusão de casos com características mais ambíguas. Esse padrão informa a decisão operacional: o limiar de operação pode ser ajustado de acordo com a capacidade da equipe e a tolerância a falsos positivos.

4.3 Análise da Matriz de Confusão

Ao limiar padrão de 0,5, o Random Forest produz a seguinte distribuição no conjunto de teste (85.443 transações, 108 fraudes): 85.334 verdadeiros negativos (legítimas corretamente classificadas), 1 falso positivo, 29 falsos negativos (fraudes não detectadas) e 79 verdadeiros positivos (fraudes




Figura 3. Curvas Precisão-Recall dos modelos comparados. O Random Forest (PR-AUC = 0,815) apresenta desempenho superior, com alta precisão para recalls de até 75%.

capturadas). O resultado de apenas 1 falso positivo em 85.335 transações legítimas é notável e evidencia o impacto do parâmetro `class_weight='balanced'` combinado com a robustez do RF.

4.4 Análise de Capacidade e Apoio à Decisão

A Figura 4 apresenta o resultado central da análise de capacidade, respondendo diretamente à pergunta-problema: para cada nível de capacidade diária da equipe de auditoria, o gráfico mostra o recall obtido (eixo esquerdo) e a precisão dos alertas (eixo direito).

Os resultados revelam três zonas operacionais de interesse:

- **Até 60 casos/dia:** o modelo mantém precisão de 100% — todos os alertas emitidos são fraudes confirmadas. Esse é o regime ideal de alta confiança, recomendado para equipes com capacidade reduzida.
- **85 casos/dia:** recall de 75,9% com precisão de 96,5% — ponto de equilíbrio operacional recomendado como referência para equipes de porte médio. A equipe cobre três quartos das fraudes existentes com altíssima confiança nos alertas.
- **Acima de 100 casos/dia:** o recall estabiliza em $\approx 78\%$ e a precisão cai progressivamente. Revisar mais casos traz retorno marginal decrescente, o que informa a decisão de alocação de recursos.

O padrão de recall que estabiliza após certo ponto reflete uma propriedade relevante do dataset: após capturar as transações mais claramente fraudulentas (altos *scores*), os casos restantes apresentam características mais ambíguas, para as quais o modelo atribui *scores* intermediários. Essa informação é valiosa para o gestor: aumentar indefinidamente a capacidade de revisão tem retorno decrescente,




Figura 4. Análise de capacidade: cobertura de fraudes (recall) e precisão dos alertas em função da capacidade diária de revisão. A linha pontilhada indica o ponto de 75% de cobertura (85 casos/dia).

sugerindo que investimentos adicionais em capacidade devem ser ponderados pela taxa de conversão marginal de fraudes capturadas.

5 Conclusão

Este trabalho desenvolveu e avaliou um sistema de apoio à decisão baseado em classificação supervisionada para priorização de transações suspeitas em auditoria de fraude em cartão de crédito. A pergunta-problema — como um modelo de classificação pode apoiar a priorização de transações a serem investigadas por uma equipe de auditoria com capacidade limitada — foi respondida por meio de duas contribuições integradas.

A primeira é técnica: o Random Forest, treinado com split temporal e parâmetro `class_weight='balanced'`, alcançou PR-AUC de 0,815, precisão de 98,75% e recall de 73,15% na classe fraude — superando significativamente a *baseline* e demonstrando robustez ao extremo desbalanceamento de classes (0,17% de fraudes). A matriz de confusão com apenas 1 falso positivo em 85.335 legítimas confirma a alta confiabilidade dos alertas gerados.

A segunda é decisória: a análise de capacidade traduz a saída probabilística do modelo em uma recomendação operacional direta. Com 85 revisões diárias, a equipe cobre 75,9% das fraudes com 96,5% de precisão — referencial prático para gestores de auditoria dimensionarem sua capacidade de investigação. A análise revela ainda o ponto de retorno decrescente (≈ 100 casos/dia), informação valiosa para alocação de recursos.

Como limitações, destacam-se: (a) o dataset cobre apenas dois dias de transações de portadores europeus de 2013, o que pode restringir a generalização para outros contextos geográficos ou temporais; (b) as variáveis V1–V28, por serem componentes PCA, não permitem interpretabilidade direta das *features* mais relevantes para a fraude.

Como trabalhos futuros, sugere-se: (i) avaliação de modelos baseados em *boosting* (XGBoost,

LightGBM) e redes neurais; (ii) incorporação de variáveis contextuais adicionais (geolocalização, dispositivo de acesso); (iii) desenvolvimento de um *pipeline* de retreinamento contínuo para adaptação ao *concept drifting* característico de padrões de fraude.

Referências

- [1] BREIMAN, L. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- [2] DAL POZZOLO, A. et al. Calibrating Probability with Undersampling for Unbalanced Classification. In: *IEEE Symposium Series on Computational Intelligence (SSCI)*, 2015, p. 159–166. DOI: 10.1109/SSCI.2015.33.
- [3] DAVIS, J.; GOADRIC, M. The Relationship Between Precision-Recall and ROC Curves. In: *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, 2006, p. 233–240.
- [4] HE, H.; GARCIA, E. A. Learning from Imbalanced Data. *IEEE Transactions on Knowledge and Data Engineering*, v. 21, n. 9, p. 1263–1284, 2009.
- [5] PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- [6] TURBAN, E. et al. *Decision Support and Business Intelligence Systems*. 9. ed. Upper Saddle River: Pearson Education, 2011.
- [7] WORLDLINE; MACHINE LEARNING GROUP – ULB. Credit Card Fraud Detection. Kaggle, 2018. Disponível em: <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>. Acesso em: jun. 2026.